Ford Logosu Tespiti İçin Sınırlayıcı Kutu Etiketli Veri Seti Oluşturma

Ahmed Gürkan Özçelik
Derin Öğrenme Yüksek Lisans, Öğrenci No: 250801017
Ostim Teknik Üniversitesi, Ankara, Türkiye
250801017@ostimteknik.edu.tr

***Özet*—Bu çalışmada, sonraki ödevlerde nesne tespiti ve sınıflandırma modellerinin eğitiminde kullanılmak üzere tek sınıflı (`ford_logo`) bir Ford logosu veri seti oluşturulmuştur. Görseller `icrawler` ile Bing'den üç turda toplanmış, EXIF yön düzeltmesi, RGB/JPEG dönüşümü, 320 px alt sınırı ve algısal özet (pHash) tabanlı tekrar temizliğinden geçirilmiş, Roboflow ile YOLO formatında etiketlenmiştir. Son veri seti 366 pozitif ve 333 negatif olmak üzere 699 görsel ve 561 sınırlayıcı kutudan oluşur; negatiflerin tamamı benzer oval amblemler, başka marka logolar, Ford model rozetleri ve rozetsiz araç ön yüzlerinden oluşan zor negatiflerdir. Veri, benzer görselleri aynı bölüme toplayan grup korumalı ve tabakalı bir yöntemle sabit tohumla (42) %70/%15/%15 oranında bölünmüştür. Etiket tutarlılığı, pozitiflerin %10'unun körlemesine yeniden etiketlenmesiyle ölçülmüş ve ortalama IoU 0.971 bulunmuştur. Etiketler ayrıca COCO JSON formatında da sunulmuştur.**

***Anahtar Kelimeler*—veri etiketleme, nesne tespiti, sınırlayıcı kutu, YOLO, COCO, veri artırma, logo tespiti**

I. GIRIŞ

Derin öğrenme tabanlı nesne tespit modellerinin başarısı büyük ölçüde eğitim verisinin niceliğine, çeşitliliğine ve etiket kalitesine bağlıdır. Yanlış ya da tutarsız etiketler modelin öğrendiği karar sınırını bozar, test kümesine sızan tekrar görseller ise başarımın olduğundan yüksek ölçülmesine neden olur. Bu ödevin amacı, veri hazırlama sürecinin tüm adımlarını (toplama, temizleme, etiketleme, bölme, kayıt formatı ve kalite kontrol) uygulamalı olarak deneyimlemek ve sonraki haftalarda hiçbir değişiklik yapılmadan PyTorch ve Ultralytics YOLO [1] eğitim kodlarına verilebilecek bir Ford logosu veri seti üretmektir.

Görsel düzeyindeki `has_logo` bilgisi sayesinde aynı veri seti logo var/yok sınıflandırması için de kullanılabilir. Tüm adımlar betiklerle tekrarlanabilir biçimde yapılmış ve veri seti ile birlikte `scripts/` klasöründe teslim edilmiştir.

II. YÖNTEM

A. Görsel toplama

Görseller `icrawler` kütüphanesinin `BingImageCrawler` sınıfı [3] ile sorgu bazlı indirilmiş; her sorgu ayrı klasöre kaydedilmiş ve her görselin kaynak adresi `raw_urls.csv` dosyasına yazılmıştır (`download_images.py`). Toplama üç turda yapılmıştır:

1) **Pozitif sorgular:** ön ızgara amblemi, bagaj kapağı rozeti, gece bayi tabelası, direksiyon logosu, anahtarlık, F-150 ön amblemi, Mustang ve Ford rozeti, eski (vintage) rozetler. Böylece farklı bağlam, açı, ölçek ve ışık koşulları kapsanmıştır.
2) **Negatif sorgular:** Subaru, Hyundai, Toyota (benzer oval amblemler), Kia, rozetsiz araç ızgaraları ve mavi/oval şirket logoları.
3) **Küçük logo turu** (`download_small_logos.py`): İlk iki turdan sonra kısa kenarı 32 px'den küçük kutu sayısı yalnızca 19'du; görsellerin çoğu yakın çekim ürün fotoğrafıydı. Uzak mesafe tespitini desteklemek için bayi binası, otopark, yoldaki araçlar, polis aracı ve otomobil fuarı gibi geniş açılı sahneler için 10 ek sorgu yapılmıştır. 292 ham görselden ön işleme sonrası kalan 280 aday elle incelenmiş, logonun küçük göründüğü 50 sahne seçilmiştir. Bu tur sonunda küçük kutu sayısı 58'e çıkmıştır.

B. Ön işleme

Ön işleme etiketlemeden *önce* uygulanmıştır (`preprocess.py`):

- EXIF yön bilgisi `PIL.ImageOps.exif_transpose` ile görsele uygulanmış, kayıtta EXIF yazılmayarak silinmiştir. Bu yapılmazsa bazı görseller eğitimde döndürülmüş okunur ve kutular yanlış yere düşer.
- Kısa kenarı 320 px'den küçük görseller elenmiştir.
- Gri, CMYK, RGBA, PNG ve WebP dahil tüm görseller RGB'ye dönüştürülüp JPEG (kalite 95) olarak kaydedilmiştir.
- Tekrarlar pHash [4] Hamming mesafesi ≤ 4 ile temizlenmiştir; bu yöntem aynı görselin farklı boyutlu kopyalarını da yakalar. Yeni turlardaki görseller mevcut tüm görsellere karşı kontrol edilmiştir.
- Logoyu kapatan filigranlı veya aşırı bulanık görseller elle silinmiş, kalanlar `ford_0001.jpg`, `neg_0001.jpg` biçiminde sıralı adlandırılmıştır.
- Görseller *orijinal boyutlarında* saklanmıştır; yeniden boyutlandırma ve veri artırma eğitim sırasında yapılacaktır.

C. Etiketleme aracı ve süreci

Etiketleme Roboflow [5] ile yapılmış ve YOLOv8 formatında dışa aktarılmıştır. İlk turda Roboflow'a ön işlenmiş görseller yerine ham görseller yüklendiği için dışa aktarılan dosya adları (`000001_jpg.rf.<hash>.jpg`) ve bazı görseller (elenmiş küçük veya tekrar eden kopyalar) ön

işlenmiş kümeyle uyuşmuyordu. Bu sorunu çözmek için `build_dataset.py` yazılmıştır. Betik her dışa aktarılan görseli pHash ile ön işlenmiş karşılığına eşler, en-boy oranını doğrular ve normalize YOLO kutularını orijinal boyutlu görsele aktarır. Elenmiş görsellerin etiketleri kullanılmaz. Birden çok etiketleme turu sırayla uygulanır ve sonraki tur öncekinin üzerine yazar. Kalite kontrolde tespit edilen düzeltmeler de bu betikte açıkça listelenmiştir (`LABEL_OVERRIDES`), böylece tüm düzeltmeler tekrarlanabilir.

D. Etiketleme kuralları

Yönergede verilen kurallar tüm veri setinde aynen uygulanmıştır: kutu logoya sıkı oturur; oval görünüyorsa ovalin dış sınırı, yalnızca yazı varsa yazı kutulanır; her logo ayrı kutu ile işaretlenir; kısmen kapanmış logoların yalnızca görünen kısmı kutulanır; yaklaşık 10 px'den küçük ve tanınamayan logolar etiketlenmez; yansıma ve ekran/poster üzerindeki tanınabilir logolar etiketlenir; negatiflerde boş etiket dosyası bulunur. Kuralların kapsamadığı durumlar için alınan özel kararlar şunlardır:

1) **Oval içinde ikinci kutu yok.** Oval görünüyorsa içindeki "Ford" yazısı ayrıca kutulanmaz. İlk turda bu kurala uymayan iç kutular, başka bir kutunun %95'inden fazlası içinde kalan ve alan oranı 0.15–0.6 olan kutuları silen bir kuralla otomatik temizlenmiştir.
2) **Model rozetleri Ford logosu değildir.** Mustang atı, F-150, Raptor, ST ve Focus rozetleri kutulanmaz; başka Ford logosu yoksa görsel zor negatiftir.
3) **Büyük harfli "FORD" yazısı** (tabela harfleri, eski arma üzerindeki yazı, bagaj kapağı harfleri) logo kabul edilir ve yalnızca yazı kutulanır.
4) **Yazısız boş oval** kapak etiketlenmez.
5) **Logo ızgaraları** (çok sayıda şirket logosu) içindeki Ford logosu 10 px sınırını geçiyorsa etiketlenir.
6) **Üst üste dizilmiş amblemler** görünen kısımları kadar ayrı ayrı kutulanır.
7) **Stok fotoğraf filigranları** logoyu kapatmıyorsa görsel tutulmuştur.
8) **10 px sınırı:** Kısa kenarı 8–9 px olup biçimi ve konumu sayesinde açıkça tanınan 5 kutu etiketlenmiştir.
9) **Örnek görseller ile yazılı kural farkı:** Yönergedeki örnek görsellerde kutu ovalin içindeki yazıyı kapsarken yazılı kural ovalin dış sınırını tarif etmektedir. Tutarlılık için tek bir tanım seçilmiş ve ölçülebilir olduğu için yazılı kural uygulanmıştır.

E. Eğitim/doğrulama/test bölmesi

Bölme `split.py` ile sabit tohum (`seed=42`) kullanılarak %70/%15/%15 oranında yapılmıştır. Pozitif ve negatifler ayrı ayrı bölünerek oran her bölümde korunmuştur (pozitif oranı train/val/test: 0.52/0.53/0.52). Aynı fotoğraf serisinden kareler veya aynı sahnenin farklı ajanslardaki kopyaları gibi çok benzer görseller, pHash mesafesi ≤ 10 olan çiftleri birleştiren bir union-find yapısıyla gruplanmış ve her grup bütün olarak tek bir bölüme atanmıştır. 699 görsel 672 gruba ayrılmış, 19 grup birden fazla görsel içermiştir. Gruplar büyükten küçüğe, hedefe göre en çok eksiği olan bölüme yerleştirilmiştir. Bu bölme sonraki ödevlerde değiştirilmeden kullanılacaktır.

Tablo I
YOLO VE COCO FORMATLARININ KARŞILAŞTIRILMASI

	YOLO	COCO
Dosya	görsel başına `.txt`	bölüm başına `.json`
Kutu	x_c, y_c, w, h (merkez)	x, y, w, h (sol üst)
Birim	normalize (0–1)	piksel
Sınıf no	0'dan başlar	`category_id` 1'den
Negatif	boş `.txt`	anotasyonsuz görsel

F. Kayıt formatı

Veri seti yönergedeki klasör yapısına uygundur: `images/{train,val,test}`, aynı adlı etiket dosyalarıyla `labels/{train,val,test}`, `data.yaml`, `classes.txt`, `metadata.csv`, `README.md`, `scripts/` ve `augmentation_ornekleri/`. YOLO etiketlerinde her satır `<sınıf> <x_merkez> <y_merkez> <genişlik> <yükseklik>` biçimindedir; değerler görsel boyutuna bölünerek 0–1 aralığına normalize edilir ve 6 ondalık basamakla yazılır. `metadata.csv` her görsel için bölüm, `has_logo`, kutu sayısı, boyut, kaynak URL ve not (ör. "zor negatif – benzer oval logo (Subaru)") bilgisini içerir.

Ek puan kapsamında etiketler COCO [2] formatında da dışa aktarılmıştır (`annotations/instances_{train,val,test}.json`). İki format arasındaki farklar Tablo I'de özetlenmiştir. Dönüşüm $x_{\text{sol}} = (x_c - w/2)\,W$, $w_{\text{px}} = w\,W$ (y ve h için H ile) şeklindedir.

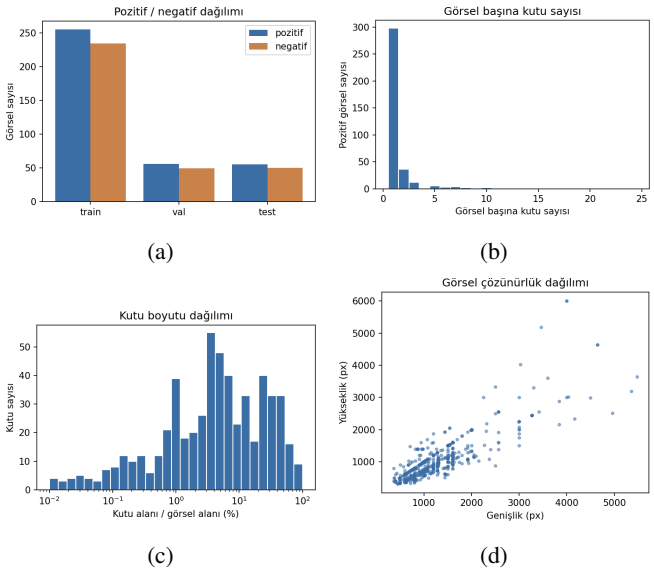
G. Kalite kontrol

- **Doğrulama betiği:** Ders kapsamında resmî bir `check_dataset.py` paylaşılmadığı için yönergede listelenen tüm kontroller bu adla yazılmıştır: klasör yapısı, `data.yaml` ve `classes.txt` içeriği, her görselin etiket dosyası (ve tersi), dosya adı biçimi, JPEG/RGB/EXIF/320 px, satır başına 5 değer, sınıf no, 0–1 aralığı ve kutunun görsel dışına taşmaması, negatif/pozitif etiket tutarlılığı, aynı dosyanın (ad veya MD5 içerik özeti) birden fazla bölümde bulunmaması ve `metadata.csv`'nin dosyalarla tutarlılığı. Betiğin hataları gerçekten yakaladığı, bilerek bozulmuş bir kopya üzerinde 7 farklı hata türüyle doğrulanmıştır. Teslim edilen veri seti **0 hata** ile geçmektedir; 5 uyarı özel karar 8'deki küçük kutulardır.
- **Görsel kontrol:** `visualize_labels.py` ile 40 rastgele görselin kutuları çizilmiş (Şekil 8), ayrıca tüm pozitifler pano halinde gözden geçirilmiştir.
- **Yeniden etiketleme:** Pozitiflerin %10'u eski kutular görülmeden ayrı bir Roboflow projesinde yeniden etiketlenmiş ve `relabel_check.py` ile karşılaştırılmıştır (Bölüm V).

Kalite kontrolde bulunan ve düzeltilen başlıca hatalar şunlardır: negatif klasöründe Ford logosu içeren 15 görsel (logo

Tablo II
BÖLÜM BAZINDA GÖRSEL VE KUTU SAYILARI

Bölüm	Görsel	Pozitif	Negatif	Kutu	Oran
train	489	255	234	377	%70.0
val	105	56	49	91	%15.0
test	105	55	50	93	%15.0
Toplam	699	366	333	561	



Şekil 1. (a) Bölüm bazında pozitif/negatif dağılımı, (b) görsel başına kutu sayısı, (c) kutu alanı/görsel alanı (log ölçek), (d) görsel çözünürlüğü.

ızgaraları, bayi tabelaları) etiketlenip pozitife aktarılmıştır; yalnızca model rozeti içeren 98 "pozitif" görsel zor negatife aktarılmıştır; oval içi ikinci kutular silinmiştir; 15 eski arma görselinde tüm armayı kapsayan kutular özel karar 3'e göre yalnızca yazıyı kapsayacak şekilde yeniden çizilmiştir.

III. Veri Seti İstatistikleri

Bölüm bazında dağılım Tablo II'de verilmiştir. Pozitif görsellerin %81'inde tek kutu bulunurken bazı ürün ve logo ızgarası görsellerinde 24'e kadar kutu vardır (Şekil 1b). Kutu alanının görsel alanına oranı log ölçekte geniş bir aralığa yayılmıştır (medyan %4.8, en küçük %0.01); küçük logo turuyla dağılımın sol kuyruğu belirgin biçimde güçlenmiştir (Şekil 1c). Görsel çözünürlükleri 369–5472 px genişlik ve 320–6000 px yükseklik arasındadır, medyan 1140×956'dır (Şekil 1d).

Normalizasyon için kanal bazında ortalama ve standart sapma yalnızca **train** kümesinin 835 milyon pikselinden hesaplanmıştır; doğrulama ve test bilgisi modele sızmasın diye diğer bölümler kullanılmamıştır:

$$\mu = [0.4822,\ 0.4749,\ 0.4899], \quad \sigma = [0.3474,\ 0.3452,\ 0.3410].$$

Zor negatiflerin dağılımı: 98 Ford model rozeti (Mustang atı, F-150, Raptor, ST), 87 başka marka oval amblem (Hyundai, Toyota), 69 benzer oval/mavi logo (Subaru, şirket logoları), 40 başka marka amblem (Kia) ve 39 rozetsiz araç ön yüzü.

Tablo III
YENIDEN ETIKETLEME SONUÇLARI (DÜZELTME ÖNCESI)

Ölçüt	İlk örnek	Ek örnek	Toplam
Görsel	32	5	37
İlk etiketlemedeki kutu	49	8	57
Eşleşen kutu (IoU $>$ 0.1)	48	7	55
Ortalama IoU	0.976	0.937	0.971
IoU $\geq$ 0.75 oranı	%100	%100	%100
Tutarsız görsel	1	1	2

IV. Örnek Görseller ve Ek Denemeler

Şekil 2 farklı bağlamlardan etiketli örnekleri, Şekil 3 zor negatif örneklerini, Şekil 4 ise küçük logo turundan büyütülmüş kesitlerle örnekleri göstermektedir.

Letterbox denemesi. Görseller ayrı bir deneme olarak oran korunarak 224×224'e yeniden boyutlandırılmış ve boşluklar gri (114) ile doldurulmuştur (`letterbox_demo.py`). Ölçek $r = \min(224/W, 224/H)$, dolgu $d_x = \lfloor (224 - \mathrm{round}(Wr))/2 \rfloor$ olmak üzere kutular $x'_c = (x_c W r + d_x)/224$, $w' = wWr/224$ dönüşümüyle güncellenmiştir (y ekseni için benzer şekilde). Şekil 5 kutuların dönüşümden sonra da logoya oturduğunu göstermektedir.

Veri artırma. Albumentations [6] ile yatay çevirme, $\pm 15°$ döndürme, parlaklık/kontrast, ölçekleme, kutuyu koruyan rastgele kırpma, renk tonu, bulanıklık ve bunların birleşimi uygulanmıştır. Kutular görselle birlikte dönüştürülmüştür (Şekil 6). Bu görseller yalnızca rapor içindir ve veri sızıntısını önlemek için train/val/test klasörlerine eklenmemiştir.

V. Yeniden Etiketleme ile Tutarlılık Ölçümü

Pozitiflerden önce 32 görsel rastgele seçilmiş (seed 42), küçük logo turu pozitif sayısını 366'ya çıkarınca oranı korumak için yeni turdan 5 görsel daha eklenmiştir (toplam 37/366 = %10.1). Görseller eski kutular görülmeden ayrı bir Roboflow projesinde yeniden etiketlenmiş ve iki etiketleme açgözlü IoU eşleştirmesiyle karşılaştırılmıştır (Tablo III).

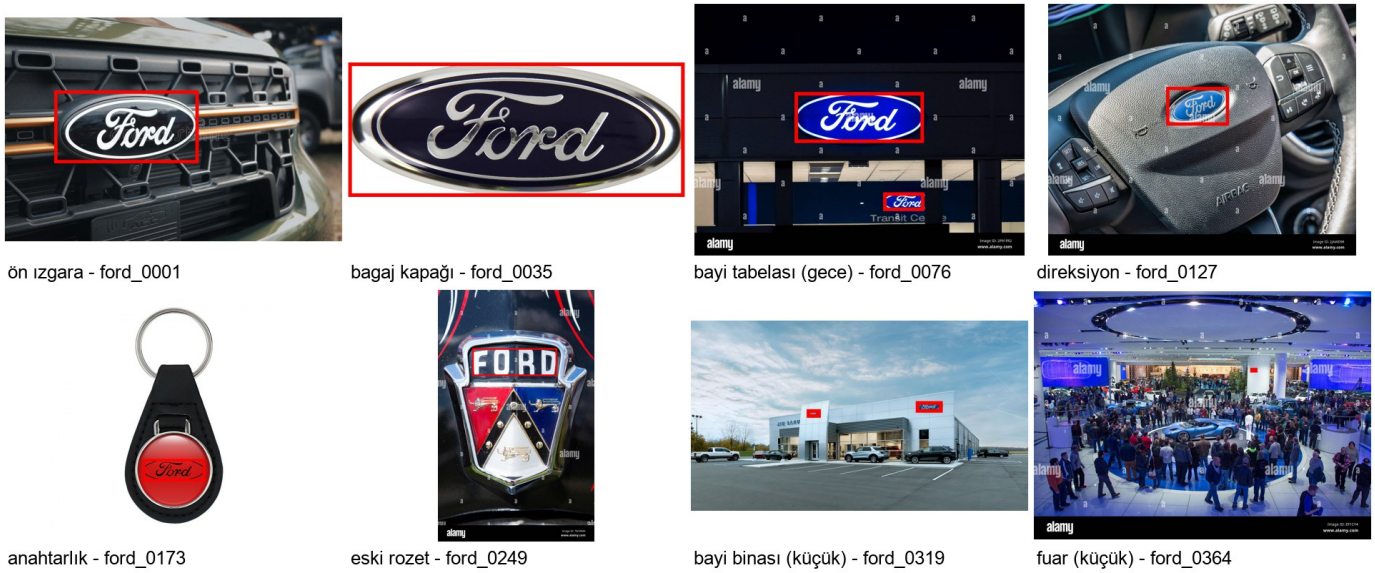
İki tutarsızlık bulunmuştur (Şekil 7):

1) `ford_0252` (eski arma): İlk etiketleme tüm armayı, ikinci etiketleme yalnızca "FORD" yazısını kapsıyordu (IoU 0.07). Özel karar 3'e göre ikinci etiket doğrudur. Bu bulgu üzerine 56 eski arma görselinin tamamı taranmış, aynı hatayı içeren 15 görsel yeniden etiketlenerek yalnızca yazı kutulanmıştır.
2) `ford_0366` (otomobil fuarı): İkinci etiketlemede arkadan aydınlatılmış, düşük kontrastlı küçük bir "Ford" tabelası atlanmıştır. Logo tanınabilir olduğundan ilk etiket korunmuştur.

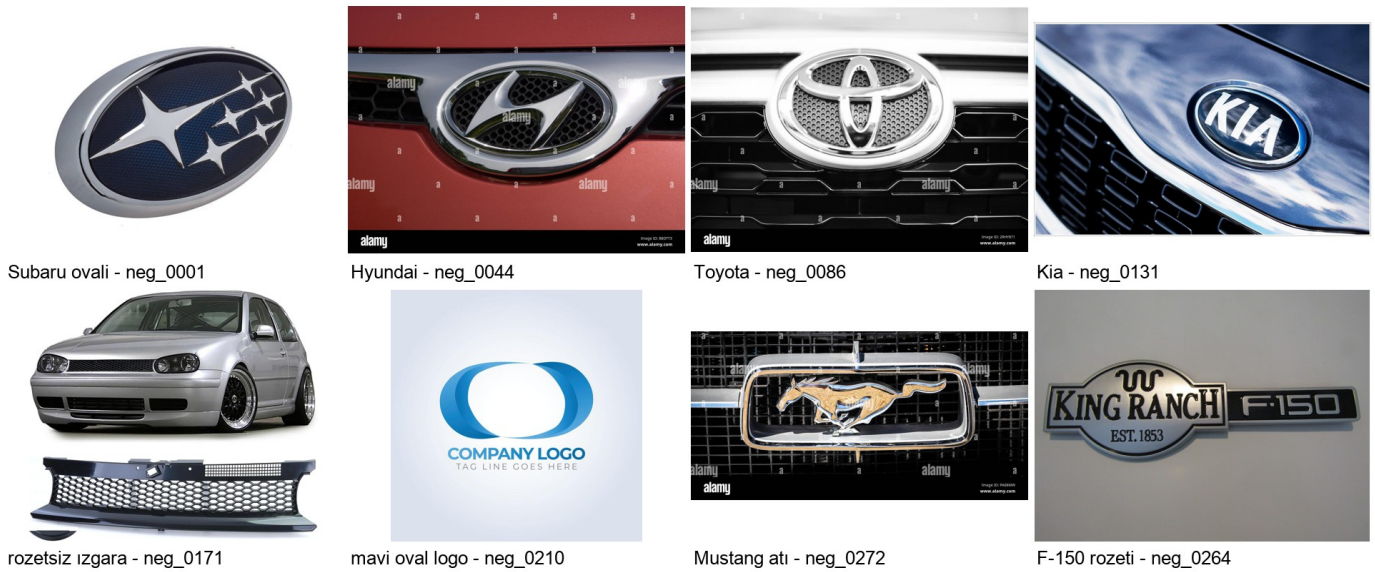
Eşleşen kutulardaki küçük farklar (IoU 0.91–0.99) kutu kenarlarının 1–3 px oynamasından kaynaklanmaktadır.

VI. Karşılaşılan Zorluklar ve Çözüm Önerileri

- **Ham ve işlenmiş görsel uyuşmazlığı:** Roboflow'a ham görsellerin yüklenmesi dosya adlarını ve görsel kümesini değiştirdi. pHash + en-boy oranı eşleştirmesiyle etiketler



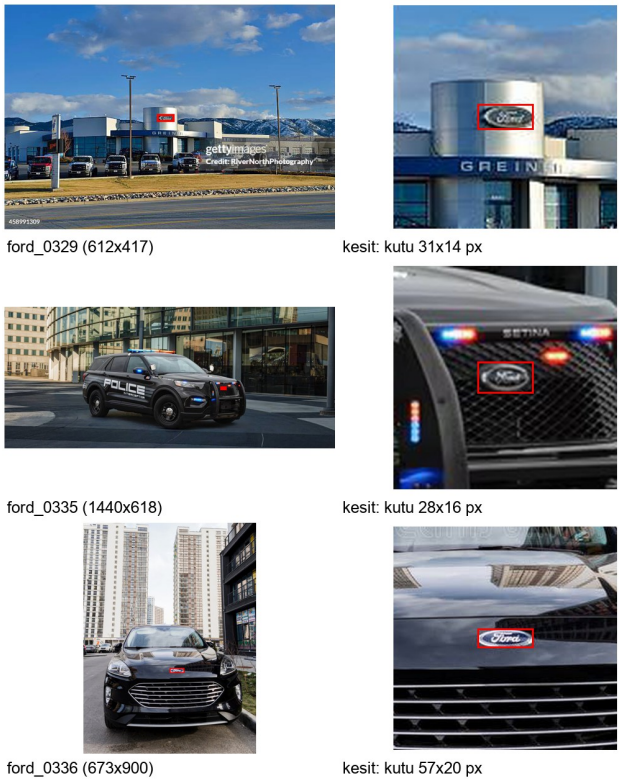
Şekil 2. Farklı bağlamlardan etiketli örnekler (kırmızı: sınırlayıcı kutu). Alt satırdaki son iki görsel küçük logo turundandır.



Şekil 3. Zor negatif örnekleri: benzer oval amblemler, başka marka logolar, rozetsiz ızgara ve Ford logosu sayılmayan model rozetleri (Mustang atı, F-150).

yeniden etiketleme gerekmeden aktarıldı. *Öneri:* Etiketleme aracına her zaman ön işlenmiş ve son adlarını almış görseller yüklenmelidir.

- **Arama sonuçlarındaki gürültü:** "Ford Mustang" gibi pozitif sorgular yalnızca model rozeti içeren görseller, "blue oval logos" gibi negatif sorgular ise Ford logosu içeren görseller döndürdü. Bunlar elle ayıklanıp doğru sınıfa aktarıldı; model rozetleri değerli zor negatiflere dönüştü.
- **Kural belirsizlikleri:** Eski armalar, oval içi yazı ve yazısız boş ovaller etiketleyiciler arasında farklı yorumlanabiliyor. Bu durumlar özel karar olarak yazılı hale getirildi. Yeniden etiketleme, belirsiz kuralların gerçek tutarsızlık ürettiğini gösterdi.
- **Ölçek dengesizliği:** Web aramaları ağırlıklı olarak yakın çekim ürün fotoğrafları döndürüyor. Hedefli bir küçük logo turuyla küçük kutu sayısı 19'dan 58'e çıkarıldı, ancak bu sayı toplam kutuların hâlâ yaklaşık %10'u. *Öneri:* Video karelerinden veya sokak görüntülerinden ek veri toplanabilir.
- **Veri sızıntısı riski:** Aynı sahnenin farklı ajans kopyaları pHash ≤ 4 eşiğinin dışında kalabiliyor. Bölmede daha gevşek bir eşikle (≤ 10) gruplama yapılarak bu kopyalar aynı bölüme toplandı.
- **Filigranlar ve kalabalık sahneler:** Stok fotoğraf filigranları ve düşük kontrastlı tabelalar etiketlemeyi zorlaştı-



Şekil 4. Küçük logo örnekleri. Sol: tam görsel, sağ: kutu çevresinden büyütülmüş kesit.



Şekil 5. Letterbox denemesi. Sol: orijinal görsel ve kutu, sağ: 224×224 letterbox sonrası dönüştürülmüş kutu.

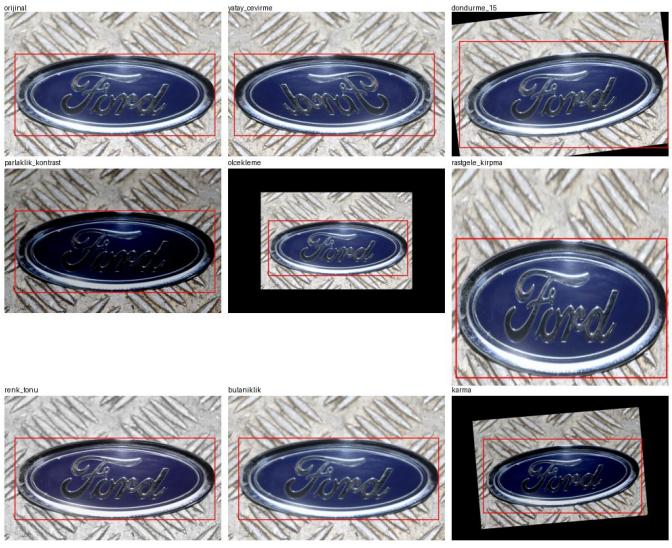
rıyor; fuar görselinde bir logo ikinci etiketlemede gözden kaçtı. *Öneri:* Kalabalık sahnelerde yakınlaştırarak ikinci bir tarama yapılmalıdır.

VII. Öğrenilen Dersler

- Etiketleme kuralları başlangıçta ne kadar açık görünse de gerçek veride sınır durumlar ortaya çıkıyor. Bu durumlar yazılı özel kararlara dönüştürülmeli ve tüm veri setine geriye dönük uygulanmalıdır.
- Tek bir yeniden etiketleme bulgusu sistematik bir hatayı ortaya çıkarabilir. ford_0252 tutarsızlığı, aynı türdeki tüm armaların taranmasını sağladı.
- Kalite kontrol için kutuları çizmek vazgeçilmezdir. Biçim hataları ve yanlış sınıf atamaları sayısal kontrollerle değil, görsel incelemeyle bulundu.
- Tüm adımların betikle ve sabit tohumla yapılması, yeni bir veri turu eklendiğinde veri setinin tamamının dakikalar içinde ve aynı sonuçla yeniden üretilmesini sağladı.
- Veri bölmede rastgelelik yeterli değildir; benzer görseller gruplanmazsa test başarımı iyimser ölçülür.

VIII. Sonuç

Bu çalışmada 699 görsel ve 561 kutudan oluşan, zor negatiflerle desteklenmiş, grup korumalı olarak bölünmüş ve YOLO ile COCO formatlarında sunulan bir Ford logosu veri seti oluşturulmuştur. Veri seti yönergedeki tüm biçim kontrollerinden hatasız geçmekte ve yeniden etiketleme ile ölçülen tutarlılığı



Şekil 6. Kutularla birlikte dönüştürülmüş veri artırma örnekleri.

yüksektir (ortalama IoU 0.971). Veri seti, sonraki ödevlerde nesne tespiti ve logo var/yok sınıflandırması için doğrudan kullanılacaktır.

Kaynaklar

[1] G. Jocher, A. Chaurasia ve J. Qiu, "Ultralytics YOLOv8," 2023. [Çevrimiçi]. Erişim: https://github.com/ultralytics/ultralytics



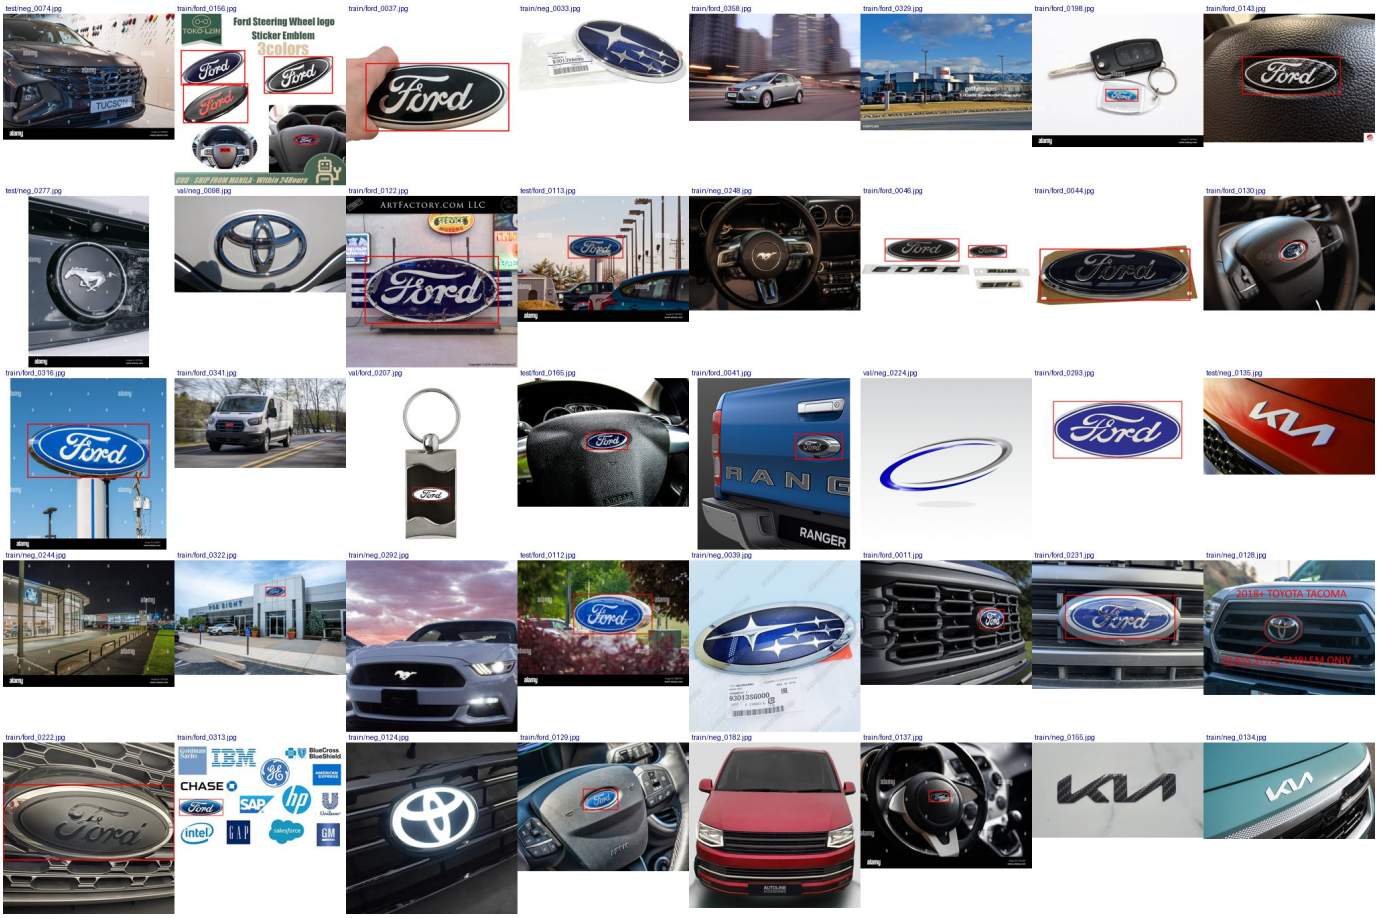
ford_0252



ford_0366

Şekil 7. Yeniden etiketlemede bulunan tutarsızlıklar (yeşil: ilk, kırmızı: ikinci etiketleme).

[2] T.-Y. Lin *vd.*, "Microsoft COCO: Common objects in context," *Proc. European Conference on Computer Vision (ECCV)*, 2014, ss. 740–755.
[3] K. Chen, "icrawler: A multi-thread crawler framework," [Çevrimiçi]. Erişim: https://github.com/hellock/icrawler
[4] J. Buchner, "ImageHash: A Python perceptual image hashing module," [Çevrimiçi]. Erişim: https://github.com/JohannesBuchner/imagehash
[5] Roboflow, "Roboflow Annotate," [Çevrimiçi]. Erişim: https://roboflow.com
[6] A. Buslaev *vd.*, "Albumentations: Fast and flexible image augmentations," *Information*, c. 11, sy. 2, s. 125, 2020.



Şekil 8. Kalite kontrol panosu: kutuları çizilmiş 40 rastgele görsel (seed 42).